Introduzione al calcolo parallelo con Apache Spark



Vincenzo Manzoni, Andrea Rota Analytics on Industrial Processes



Tenaris



Leader mondiale nella produzione e fornitura di prodotti tubolari e servizi per:

- Trivellazioni, estrazione e produzione di petrolio e gas
- Trasporto di petrolio e gas
- Impianti di trasformazione e centrali elettriche
- Applicazioni specialistiche industriali e automotive



OCTG



Giunti Premium



Linepipe per applicazioni onshore e offshore



Trasformazione di idrocarburi



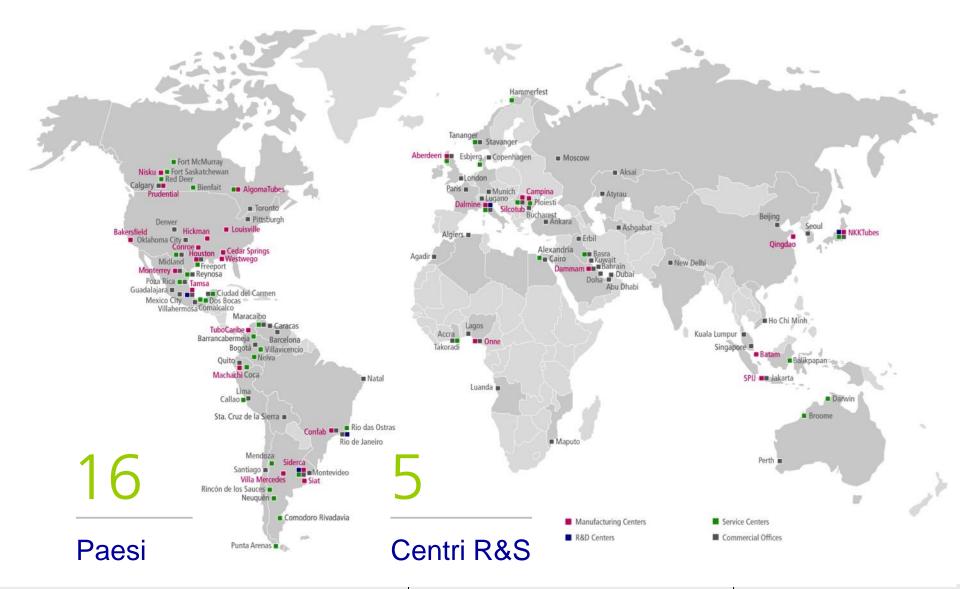
Generazione di energia



Applicazioni industriali e automotive

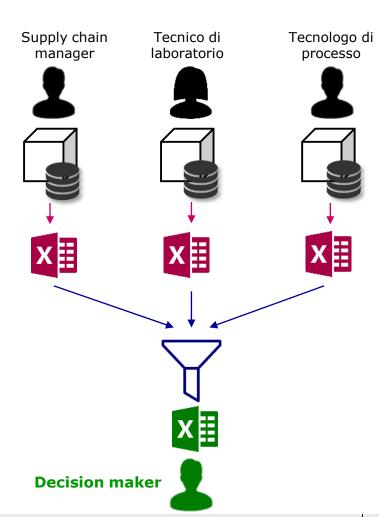
Tenaris nel mondo





Background





Data users

Competenze diverse (tipologia e livello di maturità) Esigenze diverse

Applicazioni di data analytics

Verticali Sviluppate custom Tecnologie eterogenee Non *mobile-ready*

Export

Report strutturati e non strutturati Diversi formati Autorizzazione su ogni sistema Tempo di download

Merge

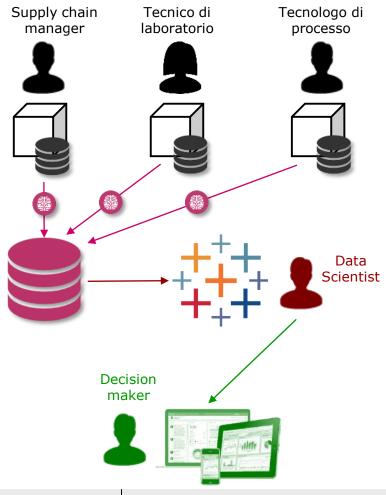
Operazione manuale \rightarrow error prone Time consuming Non real-time Qualità funzione delle capacità dell'utente

60

2

Implementazione Big Data in Tenaris





Perché Big Data



- La velocità con cui vengono prodotti i dati cresce più velocemente della capacità di una singola macchina per elaborarli.
- Il volume dei dati cresce più velocemente della capacità di storage di una singola macchina.

Serve una tecnologia per esprimere ad alto livello analisi in parallelo su grandi quantità di dati.

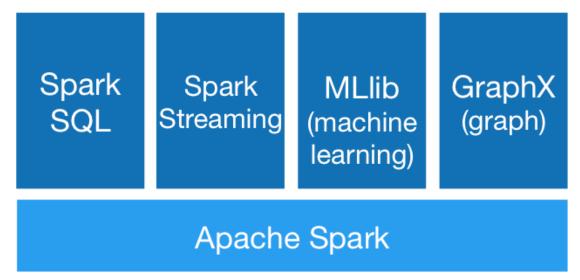




Framework open-source sviluppato dall'AMPLab dell'Università di Berkeley.

A differenza di paradigmi precedenti – tipo Map-Reduce – Spark usa primitive in memoria (fino a 100x in termini di prestazioni).

Supporta diversi linguaggi di programmazione, tra cui Java, Scala e Python.









Parola	Occorrenze
I	3
Am	3
Sam	3
Do	1
You	1
Like	1



Parola	Occorrenze
I	1



Parola	Occorrenze
I	1
Am	1



Parola	Occorrenze
I	1
Am	1
Sam	1



Parola	Occorrenze
I	2
Am	1
Sam	1

Contare le parole di un testo (molto) lungo (1/3)



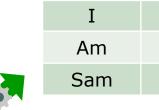
I am Sam
I am Sam
Sam I am
Do you like
Green eggs and ham
I do not like them
Sam I am
I do not like
Green eggs and ham
Would you like them
Here or there?

Contare le parole di un testo (molto) lungo (2/3)



I am Sam
I am Sam
Sam I am
Do you like
Green eggs and ham
I do not like them
Sam I am
I do not like
Green eggs and ham
Would you like them
Here or there?





Parola



Parola	Occ.
Do	2
You	1
Like	2

Occ.

3



Parola	Occ.
I	3
Am	3
Sam	3
Do	1
You	1
Like	1



Parola	Occ.
Do	2
You	1
Like	2



Contare le parole di un testo (molto) lungo (3/3)



I am Sam
I am Sam
Sam I am
Do you like
Green eggs and ham
I do not like them
Sam I am
I do not like
Green eggs and ham
Would you like them
Here or there?

	Parola	Occ.
	I	3
	Am	3
	Sam	3
	Parola	Occ.
	Do	2
E	You	1
	Like	2
	Parola	Occ.
	Do	2
	You	1
	Like	2

*	Parola	Occ.
	I	3
	Am	3
B • B • B	Sam	3
	Do	1
	You	1
0	Like	1

Map

Reduce

Demo time!

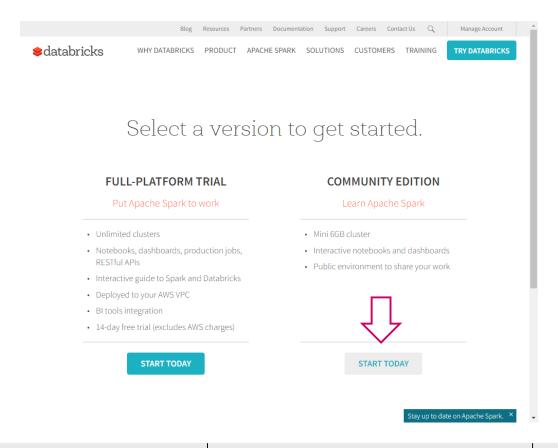


https://github.com/tenaris/scala-spark-workshop

Setup Databricks



https://databricks.com/try-databricks



Login databricks



https://community.cloud.databricks.com/



Join the dark side!



Siamo alla ricerca di studenti del 5 anno per tesi, tirocini e assegni di ricerca su tematiche **Big Data**, **Machine Learning** e **Artificial Intelligence**.

Per candidarvi, scrivete una mail a:

Vincenzo Manzoni vmanzoni@tenaris.com

